

# Stromy

---

V teorii grafů se jako strom označuje neorientovaný graf, který je souvislý a neobsahuje žádnou kružnici.

**Jedná se o hierarchickou strukturu, kde každý otec má  $N \geq$  dětí a každé dítě právě jednoho otce takovým způsobem, že v této struktuře nejsou cykly.**

Uzel, který je praotcem všech ostatních uzlů nazveme kořenem (z pohledu teorie grafů tím vytvoříme orientovaný strom).

Uzel, který nemá žádné potomky, nazýváme listem.

Být stromem je rekurzivní vlastnost - **každý podstrom stromu S je také stromem.**

Strom je velmi populární pro svoji jednoduchost a použitelnost. Příkladem mohou být vyhledávací stromy nebo haldy.

Častý strom je dichotomický, který má z každého uzlu 2 pointery: na levý podstrom a na pravý podstrom

# Binární strom

Binární strom = dichotomický strom, pro který navíc platí, že všechny klíče v levém podstromu jsou menší a v pravém podstromu větší než klíč

(Předpoklad: klíče jsou jednoznačné)

Nejdůležitější vlastnost: snadné a velmi rychlé hledání půlením.

Je-li  $N$  počet uzlů, tak počet kroků  $\approx \log_2 N$ .

## Příklad

Jako příklad si ukážeme hledání klíče 28 v binárním stromu.

Pokud hledáme [neexistující klíč](#), snadno ověříme, že opravdu neexistuje.

## Implementace

Binární (a také dichotomické, AVL i další) stromy se dají implementovat mnoha způsoby. Z nich nejčastější jsou:

- pomocí pole (halda = *heap*)
- dynamické struktury propojené referencemi (vzdálená podoba s jednoduchým spojovým seznamem)

*Pozor, "halda=heap" je slangový výraz; v matematice se používá pro něco jiného.*

*Heap* je způsob, jak binární strom zapsat do pole (a ušetřit tak místo za reference).

Vychází z toho, že binární strom má v kořenu 1 uzel, v 1. úrovni 2 uzly, ve 3. úrovni 4 uzly atd, tedy v  $N$ -té úrovni je  $2^N$  uzlů.

Proto se v poli postupně pro  $i$ -tou úroveň přidělí  $2^i$  pozic (místa pro uzly, které ve stromu chybí, zůstanou prázdná).

Poměrně jednoduchým algoritmem se dá najít vztah mezi pozicí uzlu v binárním stromě a mezi jeho indexem v poli=*heapu*.

Protože pozice všech uzlů jsou známy, lze pomocí heapu realizovat mnohé algoritmy, které pomocí pointerů napsat nelze.

# Heap – výpočet indexu

Výpočet vztahu mezi pozicí a indexem je jednoduchý.

Nechť kořen je na indexu 1.

Jestliže jsme v uzlu s indexem  $K$ , tak (pokud existují):

- jeho rodič má index  $K \text{ div } 2$
- levý podstrom má index  $2 * K$
- pravý podstrom má index  $2 * K + 1$

# Implementace strukturou odkazů

```
public class Node {  
    public static Node root = null;  
    public int key;  
    public String data;  
    public Node left = null;  
    public Node right = null;  
  
    public Node(int aKey, String aData){  
        key    = aKey;  
        data   = aData;  
        left   = null;  
        right  = null;  
    }  
}
```

```
public Node add(int aKey, String aData) {  
    if (aKey == key) {  
        System.err.println  
            ("duplicate key " + aKey);  
        return null;  
    } else if (aKey < key) {  
        if (left == null) {  
            left =  
                new Node(aKey, aData);  
            return left;  
        } else  
            return left.add  
                (aKey, aData);  
    } else if (aKey > key) {  
        if (right == null) {
```



```
        right =  
        new Node(aKey, aData);  
        return right;  
    } else  
    return right.add  
        (aKey, aData);  
}  
return null; // for sure  
}
```

```
public Node find(int aKey){  
    Node marker = root;  
    while(marker != null){  
        if (marker.key == aKey){  
            break; // found  
        }  
    }  
}
```

```
        } else if (marker.key < aKey) {  
            marker = marker.left;  
        } else {  
            marker = marker.right;  
        }  
    }  
    return marker;  
}
```

## Nevýhoda binárního stromu

Při nevhodném pořadí vkládaných uzlů mohou větve narůstat nerovnoměrně, až v krajním případě může strom [zdegenerovat](#) na lineární seznam.

# AVL stromy

Odstraňují hlavní slabinu binárního stromu.

AVL strom je binární strom, u kterého navíc **pro každý jeho uzel platí**, že výška levého podstromu se od výšky pravého podstromu liší nejvýše o 1

$$\text{abs( High(L) - High(P) )} \leq 1$$

čili **Nevyváženost**  $\leq 1$

Pomocí Nevvyváženosti je definováno, co AVL strom je, ale nijak se tím neřeší, jak ho vytvořit.

Platí: každý binární strom lze přetransformovat na AVL strom, a to pomocí konečného počtu rotací, **aplikovaných na vhodné uzly stromu**.

## Rotace stromu

Předpokládejme následující [výchozí stav](#). Hvězdička označuje kořen.

V [prvním kroku](#) změníme kořen na uzel „26“. Kdyby se jednalo o rotaci podstromu, změníme referenci, co vedla na uzel 32 tak, aby ukazovala na uzel 26.

Ve [druhém kroku](#) obrátíme směr větve, aby byla dodržena podmínka, že do kořene nevedou žádné větve.

Tím bohužel vznikne [situace](#), že z uzlu vycházejí tři větve, což je nepřípustné. Proto uzel 28 napojíme pod uzel 32.

Zde je zobrazen výsledný [strom](#).

*Poznámka: Strom, který nám po rotaci vyšel, **není** AVL. To je proto, že jsme rotaci neaplikovali na správný uzel.*

## Rotace - poznámky

Pozor, nikde ale není psáno, že každá rotace (a nad každým uzlem) musí vést k výsledku! Nevhodná aplikace může situaci i zhoršit.

Podobně jako pravá rotace, existuje i **levá rotace**. Je zcela symetrická (*zkouší se!*)

# Rotace - principy

Princip, podle kterého se aplikují rotace, vychází z faktu, že k AVL stromu lze uzel přidat v zásadě 6 způsoby:

# 2-3-4 stromy

## Motivace

Jsou problémy s častým vyvažováním při vytváření stromu.  
Jediná možnost - uvolnění pravidel.

Možnost navázat na uzel více dětí, tedy vícecestné uzly.

2-3-4 stromy mohou mít 1,2,3 datové položky v uzlu, a tedy 2,3,4 děti.

## Co znamená 2-3-4 strom

2,3,4 je počet dětí uzlu:

- uzel s 1 datovou položkou musí mít 2 děti

- uzel s 2 datovými položkami musí mít 3 děti
- uzel s 3 datovými položkami musí mít 4 děti

Uzel nesmí mít pouze jednoho syna.

List nesmí být nikdy prázdný.

Duplicitní hodnoty nejsou ve stromu povoleny.

Důsledek: List může obsahovat 1,2 nebo 3 datové položky

## **Pravidla**

Označme: A,B,C ... datové položky, a,b,c ... děti.

Pravidla jsou velmi podobná binárnímu vyhledávacímu stromu:

- Všechny klíče v podstromu a musí být menší než klíč A



- Všechny klíče v podstromu b musí být větší než klíč A a menší než klíč B
- Všechny klíče v podstromu c musí být větší než klíč B a menší než klíč C
- Všechny klíče v podstromu d musí být větší než klíč C

## Vyhledávání

Velmi podobné jako u binárních stromů:

- začíná se v kořenu
- pokud uzel neobsahuje hledaný klíč, vybere se vhodný potomek a hledání se opakuje
- pokud ani v listu hledaný klíč není, pak není ve stromu vůbec

## Vkládání

**Nová položka se vkládá vždy do listu**, protože až v listu máme jistotu, že podobná hodnota neexistuje.

Dvě možné situace při hledání místa pro vložení:

- na cestě není naplněný uzel
- na cestě je naplněný uzel

## Uzel není naplněný

Situace, kdy na cestě nikde není naplněný uzel:

- Přidání do položky neovlivní strukturu stromu
- Operace vkládání je jednoduchá.

## Příklad

Příklad: do [tohoto](#) stromu vložit 7.

7 je menší než 11, proto postupujeme [levou](#) větví.

V tomto uzlu sice je pro klíč 7 dost místa, ale není to list. Proto ho sem vložit nejde. Postupujeme [pravou](#) větví.

Výsledný strom je na [obrázku](#).

## Uzel je naplněný

Situace, že se kdekoliv po cestě najde plný uzel znamená, že musí dojít k jeho rozdělení, což má za následek vyvážení stromu.

Jak rozdělit uzel:

- vytvořit nový uzel a přesunout do něj největší prvek
- prostřední prvek přesunout do rodičovského uzlu (=vytlačit nahoru)
- upravit vazby

## Příklad

Vložte klíč 24 do tohoto stromu.

Když zkusíme vložit klíč 24, tak hned v kořeni stromu nalezneme úplně zaplněný uzel. Proto tento uzel musíme rozdělit.

Detail rozdělení ukazuje [obrázek](#). Uzel 11-40-60 se rozdělí na 3 uzly: 11, 40 a 60. Z toho 11 a 60 zůstanou na původní úrovni, zatímco 40 je vytlačen nahoru.

Po [rozdělení](#) má náš strom o 1 patro víc.

## Poznámky

Proč jsme [zde](#) 24 nevložili vedle 11?

Nová položka se vkládá vždy do listu, protože až v listu máme jistotu, že podobná hodnota neexistuje.

Výsledný strom je [zde](#).

Proč rozdělovat cestou dolů?

Zjednodušuje to práci:

- ve vyšším patře určitě není plný uzel, protože pokud byl, už je rozdělen
- takže rozdělení uzlu (posunutí položky výš) nezpůsobí problém

# 2-3 stromy

## Přehled

2-3 strom je druh stromu, jehož každý vnitřní uzel má buď dva potomky a obsahuje jeden klíč, nebo má tři potomky a obsahuje dva klíče. Všechny listy leží ve stejné hloubce.

2-3 stromy lze považovat za [B-stromy](#) obsahující vnitřní uzly pouze s dvěma nebo třemi potomky.

Díky stejné hloubce listů se 2-3 strom řadí mezi vyvážené stromy.

Hloubka 2-3 stromu s  $n$  prvky se pohybuje v rozmezí mezi  $\log_3 n$  a  $\log_2 n$ , podle použité struktury.

Tomu odpovídá i náročnost operací, jako je vyhledávání, vkládání a odebírání dat z 2-3 stromu.

2-3 stromy jsou velmi podobné 2-3-4 stromům. Rozdíly:

- uzly mohou obsahovat 1 nebo 2 položky
- uzly ukazují na 2 nebo 3 potomky

Operace hledání

- probíhá stejně jako u 2-3-4 stromu
- změní se pouze počet prohledávaných položek



Operace vkládání

- probíhá úplně jinak. . .

## Vkládání do 2-3 stromů

Co se změnilo?

Při rozdělení jsou nutné tři položky:

- jedna, která zůstane
- jedna, která se přesune do sourozence
- jedna, která se přesune do rodiče

Jenže 2-3 strom má v uzlu pouze dvě položky. Kde vzít třetí položku?

- musí se použít vkládaná položka
- **proto nelze upravovat cestou dolů**

## Vkládání do neplného listu

Vkládání do neplného listu je bez problémů:

## Vkládání do plného uzlu s neplným rodičem

Je potřeba rozdělit list a přesunout střední položku do rodiče.

## Vkládání do plného uzlu, s plným rodičem

Musí dojít k rozdělení rodiče.

Případně se musí rozdělit rodič rodiče . . . atd.

Rekurzivně dál a dál, dokud se nenajde neplný uzel.

Může to vést k posunu kořene "o patro výše".

## Příklad

Musí dojít k rozdělení rodiče.

Případně se musí rozdělit rodič rodiče . . . atd.

Jenže rodič je plný, a tak ho musíme také rozdělit.

Přitom 34 je zase uprostřed, a tak ho vytlačíme...

...a je z něj nový kořen.

# B-stromy

## B-stromy řádu K

Pozor - „B“ neznamena binární, ale „Bayerovy“.

Doposud probrané struktury předpokládaly stejně rychlý přístup ke všem prvkům, což v praxi neplatí (paměť:disk až  $10^6$ ) a neomezenou velikost paměti (což také neplatí).

B-stromy dávají dobrý návod, jak optimalizovat stránkování paměti (=přesouvání mezi pamětí a diskem) z hlediska rychlosti

Každá stránka obsahuje maximálně  $2K$  a minimálně (s výjimkou kořene)  $K$  uzlů.

Každá stránka je buď list (=nevedou z ní žádné větve) anebo z ní vede  $M+1$  větví, kde  $M$ =aktuální počet uzlů ve stránce.

Strom narůstá „vzhůru“, tzn. u kořene.

Hloubka všech listů je stejná, přitom  $K$  označuje řád stromu.

Je zajištěno naplnění alespoň na 50%.

2-3-4 stromy a 2-3 stromy jsou zvláštním případem B-stromů.

## B-stromy stránkování

Model stránkování (kdyby se do paměti vešlo jen 10 uzlů).

Lze předpokládat, že bude vyžadován přístup k datům „blízko sebe“.

V paměti budeme držet vrcholovou stránku + z každé úrovně stránku na kterou se přistupovalo [naposledy](#).

## Červeno-černé stromy

Červeno-černé stromy se podobají AVL stromům a podobně se s nimi také pracuje.

Při vkládání do AVL stromu musíme udělat nejvýše 2 rotace, ale při odebírání uzlů z AVL stromu se může stát, že budeme muset rotovat skoro všechno.

Tuto nevýhodu červeno-černé stromy nemají, protože **nikdy neděláme víc jak 2 rotace**.

Červeno-černý strom je binární vyhledávací strom. Jedná se o datovou strukturu často používanou pro implementaci asociativního pole.

## Pravidla

Uzly červeno-černých stromů se označují klíčem a barvou (1 bit).

Každý uzel je buďto červený nebo černý.

Každý list (jako listy bereme v tomto případě ukazatele na null) je černý.

Pokud je vrchol červený, jsou oba potomci černí.

Každá cesta z uzlu do podřízeného listu obsahuje stejný počet černých uzlů.

## Důsledky

Hloubka stromu je logaritmická; pro  $N$  uzlů je nejvýše  $2 \cdot \log_2(N+1)$ .

Nikdy nejsou dva červené uzly pod sebou.

## Rotace

Po Insert a Delete barvy opravujeme přebarvováním na cestě do kořene, a to pomocí operace, která se nazývá [rotace](#).

Rotace jsou v zásadě stejné jako u AVL stromů.

Je ale potřeba rozebrat podstatně více případů než u AVL stromů. Zájemci naleznou podrobnější rozbor [zde](#).



# Hufmannův strom

Statistická metoda.

Vyhledáme četnosti všech znaků v řetězci a tyto znaky podle četnosti zakódujeme tak, aby nejkratší kód odpovídal nejčastějšímu znaku.

Kódy jsou binární, nejčastější znak bude tedy reprezentován 1 bitem na rozdíl od 8(16) bitů potřebných pro uložení ASCII(UTF) znaku.

Jedná se o prefixový kód, takže žádný znak není prefixem jiného znaku → kódy pro jednotlivé znaky mají různou délku a není

potřeba označovat jejich konec (každý znak reprezentuje jeden list stromu).

Kódy vytvoříme Huffmanovým stromem:

- Jednotlivé znaky označíme jako listy stromu
- Tyto listy uložíme do seznamu  $S$  ( $S$  obsahuje uzly stromu, na začátku tedy pouze leafy)
- Seznam  $S$  seřadíme podle četnosti.
- Vybereme z  $S$  dva prvky  $M, N$  s nejnižšími četnostmi  $m, n$ ,  $m < n$ .
- Vytvoříme uzel  $p$ , kde vlevo je  $M$  a vpravo je  $N$ , a jeho četnost bude  $m+n$

- Vložíme  $p$  do  $S$  a zpět na bod 3 dokud v  $S$  není jen jeden uzel.

[Příklad](#) je zde.

Strom samozřejmě musíme přenášet spolu s komprimovanými daty.

Strom můžeme reprezentovat řetězcem tak, že jej projdeme DFS algoritmem a pro každý vrchol uložíme 0 a pro každý list 1 a znak tohoto listu.

Při načítání čteme nuly a vytváříme uzly (směrem doleva). Pokud narazíme na 1, zapíšeme písmeno a vrátíme se do nejbližšího

pravého uzlu (pravý uzel rodiče, případně nejvíce levý prvek podstromu - u rodiče vpravo) .

Při dekompresi procházíme strom a rekonstruujeme zprávu.

# Obsah

Binární strom.....	3
Příklad.....	3
Implementace .....	4
Heap – výpočet indexu .....	6
Implementace dynamickou strukturou.....	7
Nevýhoda binárního stromu .....	10
AVL stromy .....	11
Rotace stromu .....	12
Rotace - poznámky .....	13

Rotace - principy .....	14
2-3-4 stromy .....	15
Motivace.....	15
Co znamená 2-3-4 strom .....	15
Pravidla.....	16
Vyhledávání .....	17
Vkládání.....	18
Uzel není naplněný .....	18
Příklad.....	19
Uzel je naplněný .....	19
Příklad.....	20

Poznámky .....	21
2-3 stromy .....	23
Přehled .....	23
Vkládání do 2-3 stromů .....	25
Vkládání do neplného listu .....	26
Vkládání do plného uzlu s neplným rodičem	26
Vkládání do plného uzlu, s plným rodičem	26
Příklad .....	27
B-stromy .....	28
B-stromy řádu K .....	28
B-stromy stránkování .....	29

Červeno-černé stromy.....	30
Pravidla.....	31
Důsledky .....	32
Rotace.....	32
Hufmannův strom .....	33
Obsah .....	37